

TP2-IBD

Francisco Paranhos, Jean Berly

June 2025

1 Introdução

Este trabalho consiste na coleta, gerenciamento, integração e análise de conjuntos de dados públicos, como solicita o enunciado. Discutiremos a escolha dos conjuntos de dados, o processo de inserção e agregação dos conjuntos de dados em um sistema de gerenciamento de bancos de dados, a etapa de análise exploratória de dados, uma análise crítica da qualidade dos dados encontrados, e um comentário a respeito da integração dos dois conjuntos de dados distintos e como eles complementam um ao outro. Também forneceremos um link para um repositório no Github que contém os dois conjuntos de dados, assim como os dicionários de dados, metadados, informações adicionais e um notebook Jupyter com a parte de código do trabalho e a análise exploratória de dados [5].

2 Escolha dos conjuntos de dados

O primeiro conjunto escolhido consiste em uma coleção de microdados sobre o ENEM separados por escola. O dataset foi obtido diretamente no Portal de Dados Abertos [3], e contém dados a respeito da localidade geográfica das escolas, assim como dados a respeito do desempenho médio dos estudantes de cada escola em diferentes edições do ENEM. Para mais informações, consulte o site do Portal ou o repositório deste trabalho.

Já o segundo conjunto escolhido contém dados de índice de desenvolvimento humano municipal (IDHM) e outros indicadores sociais separados por município. Este dataset também pode ser encontrado parcialmente no Portal de Dados Abertos [2] ou no site Atlas Brasil [4], e contém diversos indicadores sociais atrelados a cada município do país. Novamente, para mais detalhes, consulte as referências.

Além disso, para relacionar os dois conjuntos que são o foco principal do trabalho, foi necessário utilizar uma tabela do IBGE que relaciona os nomes dos municípios aos seus códigos criados pelo IBGE [1].

3 Carregamento dos conjuntos de dados

Após escolhidos os conjuntos, foi necessário carregá-los em um gerenciador de banco de dados relacional. O gerenciador escolhido foi o *Sqlite3*. Para a execução desta etapa, utilizamos a biblioteca *Pandas* para ler o arquivo csv que contém os dados e utilizamos o gerenciador dentro do ambiente do notebook jupyter. Os dados ficaram organizados no banco de acordo com o diagrama ER que está no repositório.

4 Análise exploratória de dados

Nesta etapa, primeiramente, realizamos um procedimento preparatório: recuperamos os metadados, dicionários e recriamos o diagrama ER dos dados. Todas essas informações se encontram no repositório do trabalho.

Em seguida, realizamos a limpeza dos conjuntos de dados: removemos os atributos que tinham valor nulo em todas as tuplas, renomeamos atributos, padronizamos os valores de certos atributos e utilizamos a tabela de código dos municípios do IBGE para relacionar os dois conjuntos de dados principais.

Após isso, iniciamos a parte investigativa: a partir das perguntas elaboradas em uma etapa anterior, realizamos consultas em *sql* para obter informações relevantes e utilizamos as bibliotecas *Matplotlib* e *Seaborn* para visualizar os dados. Os resultados dessa etapa também se encontram no notebook disponibilizado no repositório.

5 Sobre as fontes dos dados utilizados

Quanto ao dataset que contém os microdados do ENEM por escola, a maior limitação encontrada foi o fato de que os dados pararam de ser coletados e atualizados em 2015. Seria interessante ter dados mais recentes, para poder analisar qual foi o efeito da pandemia da COVID-19 no desempenho dos estudantes de diferentes regiões, ou como as políticas das administrações mais recentes impactaram as escolas públicas de diferentes dependências administrativas, por exemplo. Fora isso, não encontramos grandes problemas. Os dados foram fáceis de baixar, possuem dicionário claro, e não apresentam anomalias.

Por outro lado, o dataset que contém as informações de IDMH apresentou mais problemas. O conjunto possui dados de indicadores bastante específicos, como "Desagregação RURAL IDHM Longevidade", que se refere ao indicador IDHM-longevidade restrito a regiões rurais, por exemplo. Entretanto, para muitos municípios, os valores desses indicadores mais específicos foram preenchidos como nulos. Como existe um grande número desses indicadores específicos, o resultado é um conjunto de dados relativamente esparso. Outro problema encontrado foi o fato de que, originalmente, o conjunto de dados não utiliza o código de municípios do IBGE como identificador do município, e sim uma *string* com o nome do município seguido pela unidade da federação na qual o município se encontra ("Belo Horizonte (MG)", por exemplo). Essa prática não é tão segura,

uma vez que *strings* são mais suscetíveis a erros, como grafia incorreta, caracteres não identificáveis, acentuação incorreta, etc., o que prejudica a integridade do conjunto de dados. O código é uma maneira mais segura de identificar o município, e por isso fizemos essa alteração no conjunto de dados.

6 Sobre a integração dos dados

De fato, acreditamos que os dois conjuntos de dados se complementam muito bem para contribuir na análise das desigualdades entre regiões do país. Poder relacionar indicadores sociais de renda, longevidade, educação, etc., com dados de desempenho no ENEM e, simultaneamente, condicioná-los à territorialidade, realmente é importante para a discussão de políticas públicas, por exemplo. Como fica evidente na análise exploratória de dados, os dois conjuntos distintos estão correlacionados em mais de um aspecto. As perguntas que buscamos entender sobre os dados foram:

1. Será que existe uma diferença significativa no desempenho de municípios no ENEM com IDHM diferentes?
2. Qual a influência do índice de renda do IDHM de um município e o desempenho dos alunos de escolas públicas no ENEM?
3. Será que a frequência escolar impacta no desempenho dos alunos de escolas públicas no ENEM?

Para ver mais em detalhes como foram feitas as queries e os gráficos para analisar os dados, os resultados estão detalhados no notebook.

7 Conclusão

Por fim, entendemos que o objetivo didático do trabalho foi cumprido, uma vez que foi possível acessar dois conjuntos de dados públicos governamentais, recuperar informações e metadados a respeito dos conjuntos, carregá-los em um gerenciador de banco de dados, realizar um tratamento e a análise exploratória de dados e, por fim, discutir o processo e os resultados.

Referências

- [1] IBGE. **Códigos dos municípios**. Online. <https://www.ibge.gov.br/explica/codigos-dos-municipios.php>.
- [2] IDHM. Online. <https://dados.gov.br/dados/conjuntos-dados/atlasbrasil>.
- [3] INEP. **Microdados Enem-Escola**. Online. <https://dados.gov.br/dados/conjuntos-dados/inep-microdados-do-enem-por-escola>.
- [4] ipea. **Atlas Brasil**. Online. <http://www.atlasbrasil.org.br>.

- [5] **Repositório Github.** Online. <https://github.com/JeanBerly/TP2-IBD>.